

拡散モデルの概要と収束解析

枇榔 一真

関根・深澤・矢野 研究室

2026 年 1 月 19 日

目次

- 拡散モデルの目的
- time reversal formula
- 拡散モデルのアルゴリズム
- 収束解析概要
- 収束解析 (Total Variation)
- 収束解析 (2-Wasserstein distance)
- デノイジングスコアマッチング

拡散モデルの目的

- 画像などのデータ $\{x_1, \dots, x_n\} \subset \mathbb{R}^d$ が与えられており、このデータはそれぞれある未知の確率測度 P_{data} に従ってサンプリングされたものとして考える。
- 拡散モデルの目的は、自分たちの手で未知の確率測度 P_{data} に従う新たなデータを生み出すことである。
- 統計学では最尤推定などで P_{data} を近似することなどが考えられるが、ここではSDEをうまく使い、 P_{data} そのものを近似することなく P_{data} からのサンプリングだけを得ようという発想である。

time reversal formula

f, g はリプシッツ連続であると仮定し,

$$\begin{cases} dX_t = f(t, X_t)dt + g(t, X_t)dB_t & (0 \leq t \leq T) \\ X_0 \sim P_{data} \end{cases} \quad (1)$$

を考える. このとき, f, g に対する適切な仮定のもと次の定理が成り立つ.

定理 ([1], [2])

上記の SDE の解 $\{X_t\}$ が各時刻で密度関数 p_t をもち, $p_t \in H^1$ かつ $\sup_{t \in [0, T]} \|p_t\|_{H^1}$ が有界であるとき, $a(t, x) := g(t, x)g(t, x)^\top$ として,

$$\begin{cases} dY_t = (-f(T-t, Y_t) + a(T-t, Y_t)\nabla \log p_{T-t}(Y_t))dt + g(T-t, Y_t)dB_t \\ Y_0 \stackrel{d}{=} X_T \end{cases} \quad (2)$$

の解 $\{Y_t\}$ と $\{X_t\}$ の間に $Y_t \stackrel{d}{=} X_{T-t}$ ($t \in [0, T]$) という関係が成り立つ.

- 定理が成立するための仮定は [2] で与えられており, $\partial_t + L$ が準楕円型作用素であるか, $\nabla^2 a(t, x)$ が一様有界であればよい.

time reversal formula の例 (OU 過程)

$$\begin{cases} dX_t = -X_t dt + \sqrt{2} dB_t & (0 \leq t \leq T) \\ X_0 \sim P_{data} \end{cases} \quad (3)$$

このとき, 逆向き過程は次のようになる.

$$\begin{cases} dY_t = (Y_t + \nabla \log p_{T-t}(Y_t)) dt + \sqrt{2} dB_t & (0 \leq t \leq T) \\ Y_0 \stackrel{d}{=} X_T \end{cases} \quad (4)$$

time reversal formula の例 (Variance Preserving(VP) SDE)

$\beta(t) = \alpha + \frac{t}{T}(\beta - \alpha)$ ($\alpha \ll \beta$) として,

$$\begin{cases} dX_t = -\frac{1}{2}\beta(t)dt + \sqrt{\beta(t)}dB_t & (0 \leq t \leq T) \\ X_0 \sim P_{data} \end{cases} \quad (5)$$

このとき, 逆向き過程は次のようになる.

$$\begin{cases} dY_t = (\frac{1}{2}\beta(T-t)Y_t + \beta(T-t)\nabla \log p_{T-t}(Y_t))dt + \sqrt{\beta(T-t)}dB_t & (0 \leq t \leq T) \\ Y_0 \stackrel{d}{=} X_T \end{cases} \quad (6)$$

これは, 拡散モデルの解説などでよく出てくる


$$X_i = \sqrt{1 - \beta_i}X_{i-1} + \sqrt{\beta_i}Z_i \quad (1 \leq i \leq N, Z_i \sim N(0, I)) \quad (7)$$

を連続時間化したものである.

拡散モデルのアルゴリズム

次のようにすると、最初に紹介した拡散モデルの目的である P_{data} からのサンプリングが実現できる.


- 前向き SDE の初期分布として P_{data} を取るようにする.
- 逆向き SDE を走らせることができるのであれば, X_T の分布からの乱数を発生させ, 逆向き SDE を走らせることで P_{data} に従うデータを無限に得ることが可能になる.



拡散モデルのアルゴリズム

しかし、現実的には次の3つの問題が生じる。

- X_T の分布が未知なので X_T の分布からの乱数を発生させることができない
- スコア関数 $\nabla \log p_t(\mathbf{x})$ が未知なので、逆向き SDE を走らせることができない。
- SDE を走らせる際に離散化の処理が必要になるため、得られる分布に誤差が生じる



拡散モデルのアルゴリズム

1つ目の問題点「 X_T の分布が未知なので X_T の分布からの乱数を発生させることができない」に対しては、次のような解決策がある

- time reversal formula の例で紹介した2つの SDE (OU, VP SDE) はともに定常分布として $N(0, I)$ をもつため、最終時刻 T を十分大きくとれば $\mathcal{L}(X_T) \approx N(0, I)$ となることが期待できる
- なので、初期分布を $N(0, I)$ で代替して逆向き SDE を走らせる。

拡散モデルのアルゴリズム

2つ目の問題点「スコア関数 $\nabla \log p_t(x)$ が未知なので、逆向き SDE を走らせることができない。」に対しては、次のような解決策がある

- 真のスコア関数を得ることはできないので、ニューラルネットワーク $s_\theta(t, x)$ で $\nabla \log p_t(x)$ を近似する.
- スコア関数の部分を、近似したニューラルネットワークに代替して逆向き SDE を走らせる.
- $s_\theta(t, x)$ を学習する方法として、デノイジングスコアマッチングという方法が知られており、 $\int_0^T E[(s_\theta(t, X_t) - \nabla \log p(t, X_t))^2]$ を小さくするように学習する.

拡散モデルのアルゴリズム

- 3つ目の問題点「SDE を走らせる際に離散化の処理が必要になるため, 得られる分布に誤差が生じる.」という問題では離散化誤差の評価を行うことになるが, 計算が煩雑になるので今回は考えないことにする.
- スコア関数, 初期分布を代替し, 離散化して得られた逆向き SDE を走らせた場合, 実際にどの程度 P_{data} に近い分布が得られるのかを解析する研究が多く存在する.

収束解析概要

以下では、議論を見やすくするために前向き過程は OU 過程として考える。真の逆向き SDE

$$\begin{cases} dY_t = (Y_t + \nabla \log p_{T-t}(Y_t))dt + \sqrt{2}dB_t & (0 \leq t \leq T) \\ Y_0 \stackrel{d}{=} X_T \end{cases} \quad (8)$$

に対して、スコア関数と初期分布を置き換えた

$$\begin{cases} dY'_t = (Y'_t + s_\theta(T-t, Y'_t))dt + \sqrt{2}dB_t & (0 \leq t \leq T) \\ Y'_0 \stackrel{d}{=} N(0, I) \end{cases} \quad (9)$$

を考え、2つの確率分布 $\mathcal{L}(Y_T)$ と $\mathcal{L}(Y'_T)$ を比較する。先行研究での比較方法は主に次の2通りに分類される。

- 1 Total Variance distance, KL divergence
- 2 2-Wasserstein distance

収束解析 (Total Variation)

Definition

可測空間 $(\Omega, \mathcal{F})$ 上の確率測度 P, Q の Total Variation distance $d_{TV}(P, Q)$ を, 次のように定義する.

$$d_{TV}(P, Q) = \sup_{A \in \mathcal{F}} |P(A) - Q(A)|$$

Definition

可測空間 $(\Omega, \mathcal{F})$ 上の確率測度 $P, Q (P \ll Q)$ の KL divergence $D_{KL}(P|Q)$ を, 次のように定義する.

$$D_{KL}(P|Q) = E_P[\log \frac{dP}{dQ}]$$

- Total Variation distance は距離の公理を満たすが, KL divergence は満たさない.

収束解析 (Total Variation)

Theorem (Pinsker の不等式)

任意の確率測度の P, Q に関して, 次の関係が成立する.

$$d_{TV}(P, Q) \leq \sqrt{\frac{1}{2} D_{KL}(P|Q)}$$

- Pinsker の不等式を使って, KL divergence で評価したものを TV での評価に置き換えられる.
- 先行研究は TV, KL での評価をしたものが多く, 体感では 20-30 くらい論文がある.(もっとあるかもしれない)

収束解析 (Total Variation)

- 2022 年の論文 [4] 以前は, P_{data} に対数凸性を課したり, log-sobolev 不等式が成立することを仮定したりなど, データ分布へ重ための仮定を課した解析などしか無かった.
- [4] では, 比較的自然? な次の 3 つの仮定のもと解析をしている.

仮定

- ① $\nabla \log p_t$ は L -リプシッツ連続 ($L > 0, t \in [0, T]$)
- ② $\int_{\mathbb{R}^d} |x|^2 dP_{data}(x) < \infty$
- ③ $E[|s_\theta(t, X_t) - \nabla \log p_t(t, X_t)|^2] < \epsilon^2 \quad (\forall t \in [0, T])$

収束解析 (Total Variation)

仮定

- ① $\nabla \log p_t$ は L -リプシッツ連続 ($L > 0, t \in [0, T]$)
- ② $\int_{\mathbb{R}^d} |x|^2 dP_{data}(x) < \infty$
- ③ $E[|s_\theta(t, X_t) - \nabla \log p_t(t, X_t)|^2] < \epsilon^2 \quad (\forall t \in [0, T])$

上の仮定のもと、次が成り立つ.

定理 ([4])

$$d_{TV}(P_{data}, \mathcal{L}(Y_T^I)) \leq \sqrt{KL(P_{data}|\mu)}e^{-T} + \epsilon\sqrt{\frac{T}{2}}$$

収束解析 (Total Variation)

証明 真の逆向き SDE

$$\begin{cases} dY_t = (Y_t + \nabla \log p_{T-t}(Y_t))dt + \sqrt{2}dB_t & (0 \leq t \leq T) \\ Y_0 \stackrel{d}{=} X_T \end{cases} \quad (10)$$

に対し, 加えてスコア関数だけを置き換えた SDE を

$$\begin{cases} dY_t^{score} = (Y_t^{score} + s_\theta(T-t, Y_t^{score}))dt + \sqrt{2}dB_t & (0 \leq t \leq T) \\ Y_0^{score} \stackrel{d}{=} X_T \end{cases} \quad (11)$$

に対して, スコア関数と初期分布を置き換えた SDE を

$$\begin{cases} dY'_t = (Y'_t + s_\theta(T-t, Y'_t))dt + \sqrt{2}dB_t & (0 \leq t \leq T) \\ Y'_0 \stackrel{d}{=} N(0, I) \end{cases} \quad (12)$$

とする.

収束解析 (Total Variation)

このとき, d_{TV} は距離なので次のように変形できる.

$$\begin{aligned} d_{TV}(P_{data}, \mathcal{L}(Y'_T)) &= d_{TV}(\mathcal{L}(Y_T), \mathcal{L}(Y'_T)) \\ &\leq d_{TV}(\mathcal{L}(Y_T), \mathcal{L}(Y_T^{score})) + d_{TV}(\mathcal{L}(Y_T^{score}), \mathcal{L}(Y'_T)) \end{aligned}$$

よって, $d_{TV}(\mathcal{L}(Y_T), \mathcal{L}(Y_T^{score}))$ と $d_{TV}(\mathcal{L}(Y_T^{score}), \mathcal{L}(Y'_T))$ をそれぞれ評価すればよい.

収束解析 (Total Variation)

まず $d_{TV}(\mathcal{L}(Y_T^{\text{score}}), \mathcal{L}(Y'_T))$ の評価を行うが、ここでは次の不等式が適用できる.

Theorem (データ処理不等式)

Q を *transition kernel* とし, μ, ν をそれぞれ確率測度とし, $\mu Q(A) = \int Q(x, A) \mu(dx)$ としたとき, 次の不等式が成立する.

$$d_{TV}(\mu Q, \nu Q) \leq d_{TV}(\mu, \nu)$$

今, Y' と Y^{score} はともに共通の遷移核をもつマルコフ過程なので, 遷移格を $\{P_{s,t}\}_{s,t \in [0,T], s < t}$ とすると, μ を標準正規分布に従う確率測度として, $\mathcal{L}(Y_t^{\text{score}}) = \mathcal{L}(X_T)P_{0,t}$, $\mathcal{L}(Y'_t) = \mu P_{0,t}$ とかける. よって

$$d_{TV}(\mathcal{L}(Y_T^{\text{score}}), \mathcal{L}(Y'_T)) = d_{TV}(\mathcal{L}(X_T)P_{0,T}, \mu P_{0,T}) \leq d_{TV}(\mathcal{L}(X_T), \mu)$$

収束解析 (Total Variation)

ここで, X の定常分布が μ であることと, Pinsker の不等式などを使うと

$$d_{TV}(\mathcal{L}(Y_T), \mathcal{L}(Y_T^{score})) \leq d_{TV}(\mathcal{L}(X_T), \mu) \leq \sqrt{KL(P_{data}|\mu)}e^{-T}$$

となることがわかる.[6]

収束解析 (Total Variation)

次に, $d_{TV}(\mathcal{L}(Y_T), \mathcal{L}(Y_T^{score}))$ を評価する. P を Y の経路分布, Q を Y^{score} の経路分布とする. つまり, P, Q は $(C([0, T]), \mathcal{B}(C([0, T])))$ 上の確率測度とする. また, $K(\omega, A) = 1_A(\omega(T))$ とすると, K は transition kernel になり, $\mathcal{L}(Y_T) = PK, \mathcal{L}(Y_T^{score}) = QK$ となる. よってデータ処理不等式より,

$$d_{TV}(\mathcal{L}(Y_T), \mathcal{L}(Y_T^{score})) = d_{TV}(PK, QK) \leq d_{TV}(P, Q)$$

となるので, $d_{TV}(P, Q)$ を評価すればよいことがわかる. また, Pinsker の不等式より

$$d_{TV}(P, Q) \leq \sqrt{\frac{1}{2} KL(P|Q)}$$

となるので, $KL(P|Q)$ が評価できればよい.

収束解析 (Total Variation)

ここで, ギルザノフの定理より,

$$\begin{aligned} KL(P|Q) &= E_P\left[\log \frac{dP}{dQ}\right] \\ &= E\left[\int_0^T |s_\theta(t, Y_t) - \nabla \log p_t(Y_t)|^2 dt\right] \\ &= \epsilon^2 T \end{aligned}$$

となる. よって

$$d_{TV}(P, Q) \leq \epsilon \sqrt{\frac{T}{2}}$$

となる.

収束解析 (2-Wasserstein distance)

Definition

$\mathbb{R}^d$ 上の確率測度 P, Q に対して,

$\Pi(P, Q) = \{\pi: \mathbb{R}^d \times \mathbb{R}^d \text{ 上の確率測度} \mid \pi(\cdot, \mathbb{R}^d) = P, \pi(\mathbb{R}^d, \cdot) = Q\}$ とする。
このとき, P, Q の 2-Wasserstein distance $W_2(P, Q)$ を次のように定義する

$$W_2(P, Q) = \inf_{\pi \in \Pi} \int_{\mathbb{R}^d \times \mathbb{R}^d} |x - y|^2 d\pi(x, y)$$

- TV, KL での解析を行なった論文が多くあるのに対し, 2-Wasserstein distance での解析をしている論文は比較的少ない。(自分が見つけているものだと 4 本)
- しかし, Wasserstein distance の方が画像の類似性に関する人間の判断と合致しており, Fréchet Inception Distance(FID) と呼ばれる画像品質の評価指標も Wasserstein distance に基づいているため, この距離での解析結果も求められている。
- 一方で, 現状では TV, KL の結果と比べて重い仮定が必要になったり, 収束レートが悪かったりしている。

収束解析 (2-Wasserstein distance)

仮定

- ① $\nabla \log p_t$ は L -リプシッツ連続 ($L > 0, t \in [0, T]$)
- ② $\int_{\mathbb{R}^d} |x|^2 dP_{data}(x) < \infty$
- ③ $E[|s_\theta(t, X_t) - \nabla \log p_t(t, X_t)|^2] < \epsilon^2 \quad (\forall t \in [0, T])$

TVでの解析と同様に以下の仮定で解析したいが、現状は追加の仮定を加えた結果しか証明はされていない。加えられる仮定は、先行研究では以下のうちのいずれか1つを加えている。

仮定

- ① $s_\theta(t, x)$ は L -リプシッツ連続 ($L > 0, t \in [0, T]$)
- ② $\|s_\theta(t, X_t) - \nabla \log p_t(t, X_t)\|_\infty < \epsilon \quad (\forall t \in [0, T])$
- ③ $E[|s_\theta(t, Y'_{T-t}) - \nabla \log p_t(t, Y'_{T-t})|^2] < \epsilon^2 \quad (\forall t \in [0, T])$

今回は1つ目の追加仮定である $s_\theta(t, x)$ は L -リプシッツ連続 ($L > 0, t \in [0, T]$) を課した証明を紹介する。

収束解析 (2-Wasserstein distance)

Theorem

任意の $h > 0$ に対して, 次の不等式が成立する.

$$W_2(P_{data}, \mathcal{L}(Y'_T)) \leq \sqrt{e^{(2+4h+4L)T} W_2(\mathcal{L}(X_T), N(0, I)) + \frac{\epsilon^2}{h} \frac{e^{(2+4h+4L)T} - 1}{2 + 4h + 4L}}$$

収束解析 (2-Wasserstein distance)

証明 次の2つの SDE を考える.

$$\begin{cases} dU_t = (U_t + 2\nabla \log p_{T-t}(U_t))dt + \sqrt{2} dB_t, \\ dV_t = (V_t + 2s_\theta(T-t, V_t))dt + \sqrt{2} dB_t, \end{cases}$$

ここで, $U_0 \sim \mathcal{X}_T$, $V_0 \sim N(0, I)$ で, (U_0, V_0) が $W_2(\mathcal{L}(X_T), N(0, I))$ を達成するような分布になるようにする. この時,

$$U_t - V_t = U_0 - V_0 + \int_0^t \{U_s - V_s + 2(\nabla \log p_{T-s}(U_s) - s_\theta(T-s, V_s))\} ds$$

となるので, $|U_t - V_t|^2$ に伊藤の公式を使うと,

$$d|U_t - V_t|^2 = 2(U_t - V_t)\{U_t - V_t + 2(\nabla \log p_{T-t}(U_t) - s_\theta(T-t, V_t))\}dt$$

となる.

収束解析 (2-Wasserstein distance)

証明 よって,

$$\begin{aligned}\frac{dE[|U_t - V_t|^2]}{dt} &= 2E[|U_t - V_t|^2] \\ &\quad + 4E[(U_t - V_t)(\nabla \log p_{T-t}(U_t) - s_\theta(T - t, V_t))]\end{aligned}$$

となる. ここで $\nabla \log p_{T-t}(U_t) - s_\theta(T - t, V_t) =$
 $\nabla \log p_{T-t}(U_t) - s_\theta(T - t, U_t) + s_\theta(T - t, U_t) - s_\theta(T - t, V_t)$ なので,

$$\begin{aligned}\frac{dE[|U_t - V_t|^2]}{dt} &= 2E[|U_t - V_t|^2] \\ &\quad + 4E[(U_t - V_t)(\nabla \log p_{T-t}(U_t) - s_\theta(T - t, U_t))] \\ &\quad + 4E[(U_t - V_t)(s_\theta(T - t, U_t)) - s_\theta(T - t, V_t)]\end{aligned}$$

収束解析 (2-Wasserstein distance)

証明 ここで, ヤングの不等式より任意の $h > 0$ に対して,

$$\begin{aligned} & 4E[(U_t - V_t)(\nabla \log p_{T-t}(U_t) - s_\theta(T - t, U_t))] \\ & \leq 4hE[|U_t - V_t|^2] + \frac{1}{h}E[|\nabla \log p_{T-t}(U_t) - s_\theta(T - t, U_t)|^2] \\ & \leq 4hE[|U_t - V_t|^2] + \frac{1}{h}\epsilon^2 \end{aligned}$$

となり, また S_θ の L-リプシッツ連続性より

$$E[(U_t - V_t)(s_\theta(T - t, U_t)) - s_\theta(T - t, V_t)] \leq LE[|U_t - V_t|^2]$$

となる.

収束解析 (2-Wasserstein distance)

証明 よって

$$\frac{dE[|U_t - V_t|^2]}{dt} = 2E[|U_t - V_t|^2] \leq (2 + 4h + 4L)E[|U_t - V_t|^2] + \frac{4}{h}\epsilon^2$$

となるので, グロンウォールの補題より,

$$E[|U_T - V_T|^2] \leq e^{(2+4h+4L)T} E[|U_0 - V_0|^2] + \frac{\epsilon^2}{h} \frac{e^{(2+4h+4L)T} - 1}{2 + 4h + 4L}$$

となる.

収束解析 (2-Wasserstein distance)

証明 よって,

$$\begin{aligned} W_2(P_{data}, \mathcal{L}(Y_T')) &\leq \sqrt{E[|U_T - V_T|^2]} \\ &\leq \sqrt{e^{(2+4h+4L)T} E[|U_0 - V_0|^2] + \frac{\epsilon^2}{h} \frac{e^{(2+4h+4L)T} - 1}{2 + 4h + 4L}} \\ &= \sqrt{e^{(2+4h+4L)T} W_2(\mathcal{L}(X_T), N(0, I)) + \frac{\epsilon^2}{h} \frac{e^{(2+4h+4L)T} - 1}{2 + 4h + 4L}} \end{aligned}$$

となる.

参考文献 I

- [1] Anderson, B. D. O. (1982). Reverse-time diffusion equation models. Stochastic Process. Appl. 12 313–326.
<https://mathscinet.ams.org/mathscinet/article?mr=656280>
- [2] Haussmann, U. G. and Pardoux, E. (1986). Time reversal of diffusions. Ann. Probab. 14 1188–1205.
<https://mathscinet.ams.org/mathscinet/article?mr=866342>
- [3] Wenpin Tang and Hanyang Zhao (2024). Score-based Diffusion Models via Stochastic Differential Equations – a Technical Tutorial.
<https://arxiv.org/abs/2402.07487>
- [4] Chen, S., Chewi, S., Li, J., Li, Y., Salim, A. and Zhang, A. R. (2023). Sampling is as easy as learning the score: theory for diffusion models with minimal data assumptions.
<https://arxiv.org/abs/2209.11215>

- [5] Borji, A. (2019). Pros and cons of GAN evaluation measures. Comput. Vis. Image Underst. 179 41–65.
<https://arxiv.org/abs/1802.03446>
- [6] D. Bakry, I. Gentil, and M. Ledoux. Analysis and geometry of Markov diffusion operators. Vol. 348. Grundlehren der Mathematischen Wissenschaften [Fundamental Principles of Mathematical Sciences]. Springer, Cham, 2014, pp. xx+552. <https://link.springer.com/book/10.1007/978-3-319-00227-9>